MUSK VERSION 2

Istraživanje podataka 2

Matematički fakultet

Univerzitet u Beogradu

Maša Gačević 231/2020

Sadržaj

DataFrame Musk V2 3
Preprocesiranje podataka 5
Skaliranje podataka 5
PCA – redukcija dimenzionalnosti 6
Eksperiment sa brojem PCA komponenti 7
Modeli 9
Prvi pozivi algoritama 11
Podešavanje hiperparametara u svrhu poboljšanja modela 15
Logistic Regression 15
SVM 17
Decision tree 19
KNN 20
Random Forest 22
Komparativna analiza modela na PCA-redukovanim podacima 24
Evaluacija na originalnim (raw) podacima 25
Logistic Regression 26
SVM 27
KNN 28
Decision Tree 29
Random Forest 30
Poređenje performansi modela na raw i PCA-redukovanim podacima 31
Zaključak i osvrt na projekat 32

DataFrame Musk V2

Datafrejm korišćen u ovom projektu potiče iz skupa podataka *Musk (Version 2)* i predstavlja osnovu za problem klasifikacije molekula na MUSK i NON-MUSK klase. Skup sadrži ukupno **6598 instanci (redova)** i **169 atributa (kolona)**, što ga čini visoko-dimenzionalnim skupom podataka pogodnim za primjenu tehnika redukcije dimenzionalnosti.

Svaki red u datafrejmu odgovara jednoj konformaciji molekula, dok kolone predstavljaju različite numeričke deskriptore koji opisuju hemijske i prostorne karakteristike molekula. Prva dva atributa imaju specifičnu ulogu:

- **ID** – string koji identifikuje molekul (npr. *MUSK-211* ili *NON-MUSK-...*)
- **attr_1** – dodatni identifikator konformacije (string format)

Preostali atributi (**attr_2 do attr_167**) su numerički (tipa *int64*) i predstavljaju ulazne karakteristike za modele mašinskog učenja. Posljednji atribut (**attr_168**, tip *float64*) predstavlja ciljnu promjenljivu (labelu), gdje vrijednosti označavaju pripadnost klasi (MUSK(1) ili NON-MUSK(0)).

Analiza tipova podataka pokazuje da većina atributa pripada numeričkom tipu.

Važna karakteristika ovog skupa podataka je da **ne sadrži nedostajuće vrijednosti**, što pojednostavljuje proces pripreme podataka.

Primjer jednog reda datafrejma ilustruje strukturu podataka: vrijednosti atributa variraju u širokom opsegu (uključujući negativne i pozitivne vrijednosti), što ukazuje na potrebu za skaliranjem prije treniranja modela.

Dodatnom analizom identifikatora utvrđeno je da dataset sadrži ukupno **102 jedinstvena molekula**, od čega:

- 39 MUSK molekula
- 63 NON-MUSK molekula

Svaki molekul može imati više konformacija (redova), što znači da dataset ima hijerarhijsku strukturu (molekul → konformacije).

Zbog velikog broja atributa i potencijalne korelisanosti među njima, ovaj skup podataka je pogodan za primjenu metoda kao što je **PCA (Principal Component Analysis)** u cilju smanjenja dimenzionalnosti i poboljšanja performansi modela.

	ID	attr_1	attr_2	attr_3	attr_4	attr_5	attr_6	attr_7	attr_8	attr_9	...	attr_159	attr_160	attr_161	attr_162	attr_163	attr_164	attr_165	attr_166	attr_167	attr_168
0	MUSK-211	211_1+1	46	-108	-60	-69	-117	49	38	-161	...	-308	52	-7	39	126	156	-50	-112	96	1.0
1	MUSK-211	211_1+10	41	-188	-145	22	-117	-6	57	-171	...	-59	-2	52	103	136	169	-61	-136	79	1.0
2	MUSK-211	211_1+11	46	-194	-145	28	-117	73	57	-168	...	-134	-154	57	143	142	165	-67	-145	39	1.0
3	MUSK-211	211_1+12	41	-188	-145	22	-117	-7	57	-170	...	-60	-4	52	104	136	168	-60	-135	80	1.0
4	MUSK-211	211_1+13	41	-188	-145	22	-117	-7	57	-170	...	-60	-4	52	104	137	168	-60	-135	80	1.0

[1]

[2]

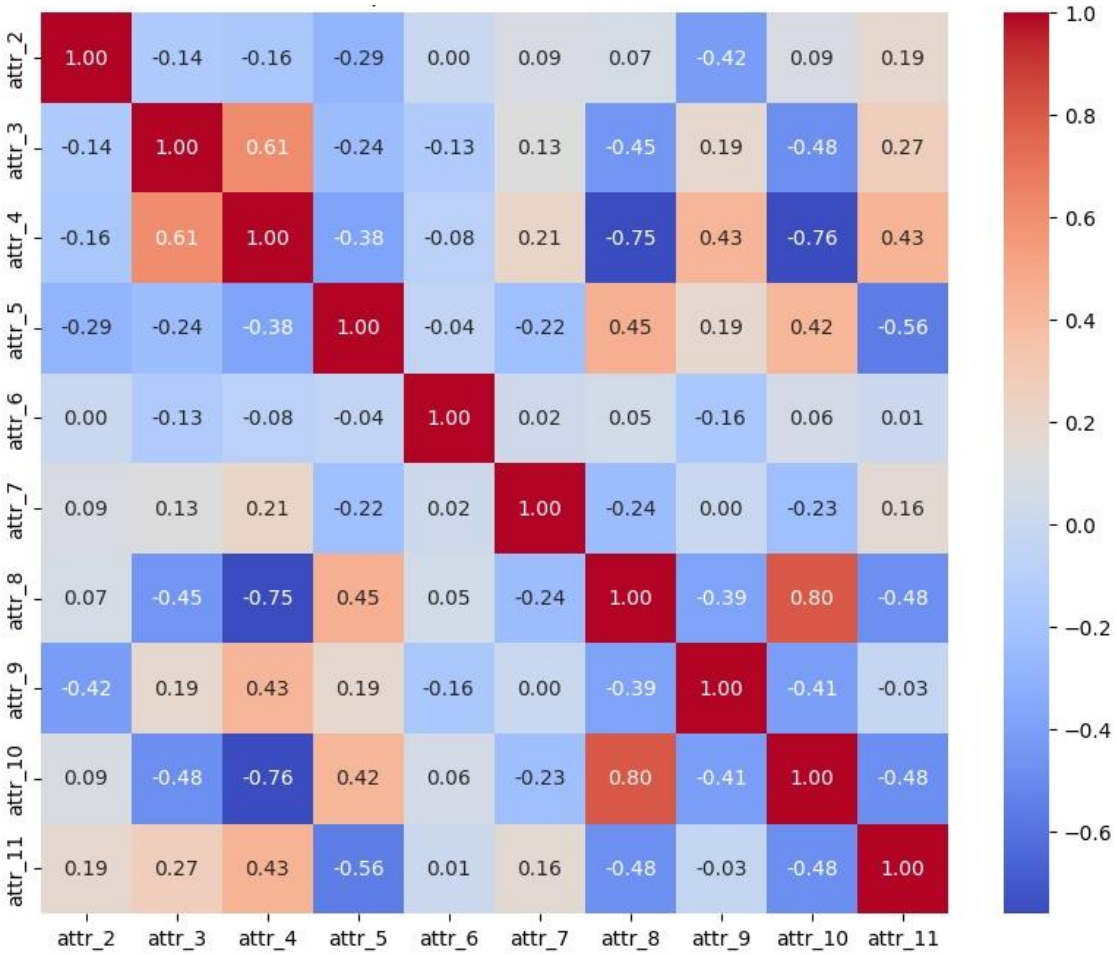

[1] Prikaz prvih pet redova df
[2] Korelaciona matrica prvih deset numeričkih atributa

Preprocesiranje podataka

Nakon inicijalne analize datafrejma, sledeći korak u obradi podataka bio je priprema ulaznih karakteristika za modele mašinskog učenja. Iz skupa podataka su najprije uklonjeni atributi **ID, attr_168** i **attr_1**, jer predstavljaju identifikatore(ID i attr_1) i ne nose informacije korisne za klasifikaciju.

Kao ulazne promjenljive korišćeni su svi preostali numerički atributi, dok je **attr_168** izdvojen kao ciljna promjenljiva.

Skaliranje podataka

S obzirom na to da numerički atributi imaju različite opsege vrijednosti (uključujući i velike negativne i pozitivne brojeve), primijenjeno je **standardizovanje podataka** korišćenjem *StandardScaler* metode.

Ova transformacija vrši centriranje podataka oko nule i skaliranje na jediničnu standardnu devijaciju. Na taj način svi atributi dobijaju jednak značaj u daljoj obradi, što omogućava modelima da uče obrasce zasnovane na stvarnim odnosima u podacima, a ne na njihovoj numeričkoj veličini.

Skaliranje je posebno važno za algoritme koji zavise od udaljenosti ili projekcija (kao što su SVM, KNN i PCA), jer bez njega atributi sa većim opsegom vrijednosti mogu imati nesrazmjerno veliki uticaj na model. Važno je naglasiti da je skaliranje izvršeno **isključivo na trening skupu**, a zatim primijenjeno na test skup, čime se izbjegava „curenje informacija" (data leakage).

PCA – redukcija dimenzionalnosti

Zbog velikog broja atributa (preko 160 numeričkih karakteristika), primijenjena je metoda **Principal Component Analysis (PCA)** sa ciljem smanjenja dimenzionalnosti prostora i uklanjanja redundantnih informacija. PCA transformiše originalne atribute u novi skup međusobno ortogonalnih komponenti koje maksimalno objašnjavaju varijansu podataka.

U ovom projektu izabrano je **20 glavnih komponenti**, pri čemu je zadržano približno:

86.55% ukupne varijanse

Ovaj rezultat ukazuje na to da relativno mali broj komponenti uspijeva da sačuva većinu informacija iz originalnog skupa podataka, što omogućava efikasnije treniranje modela uz smanjenje kompleksnosti.

Transformacija je izvršena tako što je PCA model treniran na skaliranom trening skupu, a zatim primijenjen i na test skup, čime je obezbijeđena konzistentnost transformacije.

Dodatno, PCA omogućava transformaciju originalnog prostora atributa u novi koordinatni sistem u kojem su glavne komponente sortirane po značaju, tj. po količini varijanse koju objašnjavaju. Prva komponenta objašnjava najveći dio varijanse, dok svaka naredna komponenta objašnjava preostalu varijansu uz uslov da je ortogonalna na prethodne.

Takođe, redukcija dimenzionalnosti doprinosi smanjenju šuma u podacima, jer se komponente koje objašnjavaju vrlo mali dio varijanse (a često predstavljaju šum) odbacuju.

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9	PC10	...	PC12	PC13	PC14	PC15	PC16	PC17	PC18	PC19	PC20	target
0	-0.004553	-5.878855	3.959089	-2.619893	-0.100584	-0.183060	1.261341	0.366495	-3.130402	-2.417833	...	-0.364243	-0.993755	0.005806	-0.770251	0.152365	0.777545	-0.269485	-0.361396	0.986533	1.0
1	-6.301846	2.767600	-2.201520	3.670046	3.079202	-2.639745	-0.320433	-1.340934	1.530094	0.190580	...	0.416316	0.404628	0.620328	0.636010	1.055965	2.027228	-0.360331	-2.041113	-0.063544	0.0
2	-8.322336	1.181280	-0.289148	0.332304	2.536816	-3.434377	-0.627578	-2.862797	-2.651717	-0.321618	...	-1.087653	-0.698250	-2.056685	0.809730	-1.056260	1.486202	-2.667788	0.702187	1.927491	0.0
3	-10.493467	1.877799	1.436937	-2.811511	-1.721212	5.793027	1.180827	1.046989	0.739003	-1.121751	...	-0.244211	1.903971	1.086382	2.972933	3.062903	-0.388246	-0.498012	-0.606301	-0.266161	0.0
4	7.816615	4.488584	-1.708275	3.101277	-1.935271	0.850231	-3.235592	-0.450666	-2.326863	1.578214	...	-0.725549	0.587414	-0.790005	0.799212	-0.252663	-0.975641	-0.701856	-2.233477	-0.218653	0.0

Eksperiment sa brojem PCA komponenti

Kako bi se bolje razumjelo kako broj komponenti utiče na količinu sačuvane informacije, sproveden je dodatni eksperiment u kojem je analizirana kumulativna objašnjena varijansa za različite brojeve komponenti.

Konkretno, posmatrane su vrijednosti za:

- 5 komponenti
- 20 komponenti
- 40 komponenti

Rezultati pokazuju sledeće trendove:

- **Mali broj komponenti (npr. 5)** zadržava relativno mali dio ukupne varijanse, što može dovesti do gubitka značajnih informacija i slabijih performansi modela
- **Srednji broj komponenti (20)** predstavlja dobar kompromis između redukcije dimenzionalnosti i očuvanja informacija (≈86%)
- **Veći broj komponenti (40)** dodatno povećava objašnjenu varijansu, ali uz manji dobitak u odnosu na povećanje kompleksnosti

Ovaj eksperiment jasno pokazuje tipičan PCA trade-off: povećanjem broja komponenti raste količina sačuvane informacije, ali se smanjuje efekat redukcije dimenzionalnosti.

Na osnovu ovih rezultata, izabrano je **20 komponenti** kao optimalna vrijednost, jer omogućava značajno smanjenje dimenzionalnosti uz zadržavanje većine informacija iz podataka.

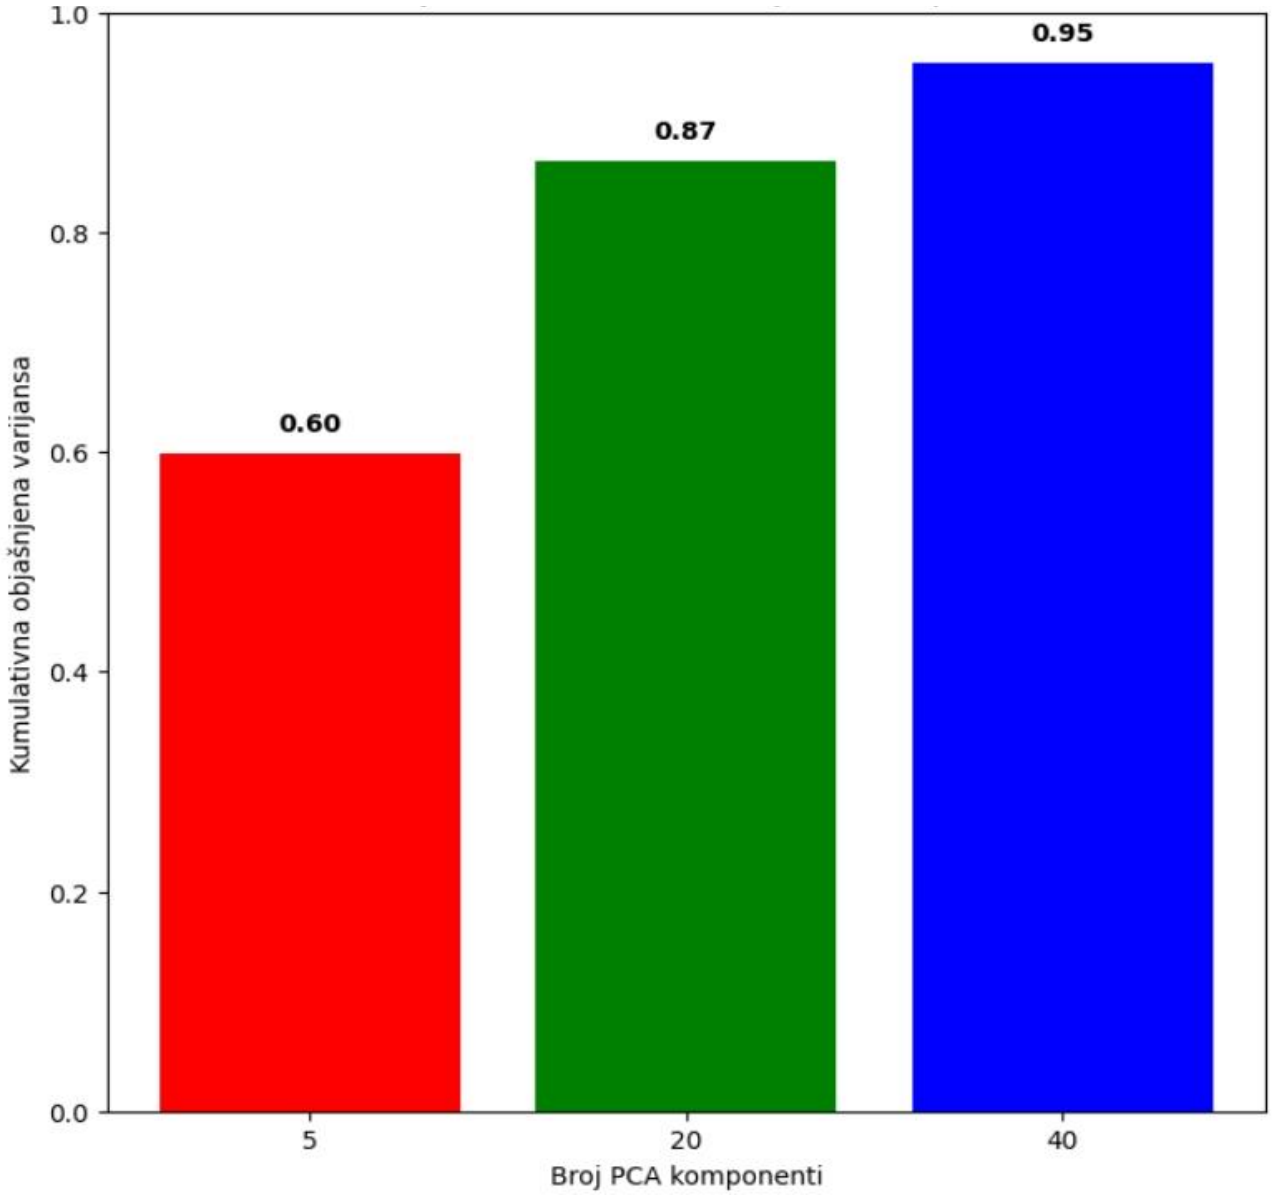

[3]

[3] Sačuvana varijansa u odnosu na različit broj komponenata

Modeli

U ovom projektu primijenjeni su različiti modeli mašinskog učenja kako bi se obuhvatili različiti pristupi rješavanju problema klasifikacije. Svaki od izabranih algoritama zasniva se na drugačijoj ideji učenja iz podataka, što omogućava bolje razumijevanje njihove primjenljivosti i ponašanja nad konkretnim skupom podataka.

Logistic Regression predstavlja linearan model koji procjenjuje vjerovatnoću pripadnosti određenoj klasi korišćenjem logističke funkcije. Iako je po svojoj prirodi jednostavan, ovaj model može biti veoma efikasan kada postoji približno linearna separabilnost između klasa. Njegova interpretabilnost i matematička jednostavnost čine ga dobrim početnim izborom za klasifikacione zadatke.

Za razliku od linearnih modela, **Decision Tree** koristi hijerarhijsku strukturu odlučivanja u kojoj se podaci sukcesivno dijele na osnovu vrijednosti atributa. Ovaj model je sposoban da uhvati nelinearne odnose između promjenljivih i lako se interpretira, jer se odluke mogu pratiti kroz grane stabla. Međutim, zbog svoje fleksibilnosti, može biti sklon pretjeranom prilagođavanju podacima.

Random Forest predstavlja ansambl metodu koja kombinuje više stabala odlučivanja kako bi se poboljšala stabilnost i tačnost modela. Ideja ovog pristupa je da se smanji varijansa pojedinačnih stabala tako što se njihovi rezultati agregiraju. Na taj način se dobija robusniji model koji je manje osjetljiv na šum u podacima.

Support Vector Machine (SVM) zasniva se na pronalaženju optimalne granice razdvajanja između klasa u prostoru karakteristika. Cilj ovog modela je da maksimizuje marginu, odnosno rastojanje između najbližih tačaka različitih klasa i granice odlučivanja. SVM je posebno efikasan u visoko-dimenzionalnim prostorima i može modelovati složene odnose između podataka.

Na kraju, **K-Nearest Neighbors (KNN)** predstavlja jednostavan, ali intuitivan model zasnovan na sličnosti između instanci. Odluka o klasi donosi se na osnovu najbližih susjeda u prostoru karakteristika. Ovaj pristup ne podrazumijeva eksplicitno treniranje modela, već se oslanja direktno na strukturu podataka, što ga čini osjetljivim na raspored i skalu atributa.

Kombinovanjem ovih modela omogućeno je sagledavanje problema iz više perspektiva – linearne i nelinearne, jednostavne i kompleksne, kao i lokalne i globalne strukture podataka. Ovakav pristup doprinosi boljem razumijevanju kako različiti algoritmi interpretiraju isti skup podataka i koje vrste obrazaca uspijevaju da prepoznaju.

Nakon izbora modela, u početnoj fazi eksperimenata korišćene su njihove podrazumijevane (default) vrijednosti parametara. Ovaj pristup omogućava uspostavljanje referentne tačke, u odnosu na koju će se kasnije podešavati hiperparametri.

Prvi pozivi algoritama

```
Logistic Regression:
  Train accuracy: 0.9115
  Test accuracy:  0.9098

Decision Tree:
  Train accuracy: 1.0000
  Test accuracy:  0.9295

Random Forest:
  Train accuracy: 1.0000
  Test accuracy:  0.9561

SVM:
  Train accuracy: 0.9610
  Test accuracy:  0.9576

KNN:
  Train accuracy: 0.9757
  Test accuracy:  0.9561
```

Dobijeni rezultati pokazuju značajne razlike u performansama modela, kako na trening, tako i na test skupu. **Logistic Regression** postiže relativno ujednačene rezultate (train ≈ 0.91, test ≈ 0.91), što ukazuje na dobru generalizaciju.

Sa druge strane, **Decision Tree** model dostiže savršenu tačnost na trening skupu (1.00), dok na test skupu postiže značajno nižu tačnost (≈ 0.93). Ovakvo ponašanje jasno ukazuje na **overfitting**, odnosno pretjerano prilagođavanje modela trening podacima. Stablo je naučilo specifične obrasce i šum iz trening skupa, što negativno utiče na njegovu sposobnost generalizacije.

Sličan trend (visoka tačnost na trening skupu) primjećuje se i kod **Random Forest** modela, ali za razliku od pojedinačnog stabla, ovaj pristup postiže znatno bolje rezultate na test skupu (≈ 0.96).

SVM model ostvaruje vrlo uravnotežene i visoke performanse (train ≈ 0.96, test ≈ 0.96), što ukazuje na dobru sposobnost generalizacije i efikasno modelovanje granice razdvajanja između klasa. Slično tome, **KNN** takođe postiže visoke rezultate, sa blagom razlikom između trening i test tačnosti, što sugeriše da model uspješno koristi lokalnu strukturu podataka.

Detaljniji uvid u performanse modela može se dobiti analizom klasifikacionih izvještaja. Na primjeru **Decision Tree** modela, koji pokazuje najizraženiji problem overfitting-a, uočava se da model znatno bolje klasifikuje dominantnu klasu (0.0) u odnosu na manjinsku klasu (1.0). Dok su precision i recall za klasu 0.0 vrlo visoki (≈ 0.96), za klasu 1.0 su značajno niži (≈ 0.76–0.78). Ovo ukazuje na to da model ima poteškoće u prepoznavanju manjinske klase, što je čest problem kod neuravnoteženih skupova podataka.

Iako ukupna tačnost modela iznosi oko 93%, analiza po klasama otkriva da performanse nisu ravnomjerno raspoređene. Upravo zbog toga je važno koristiti detaljnije metrike poput precision, recall i F1-score, jer one pružaju realističniju sliku o kvalitetu modela.

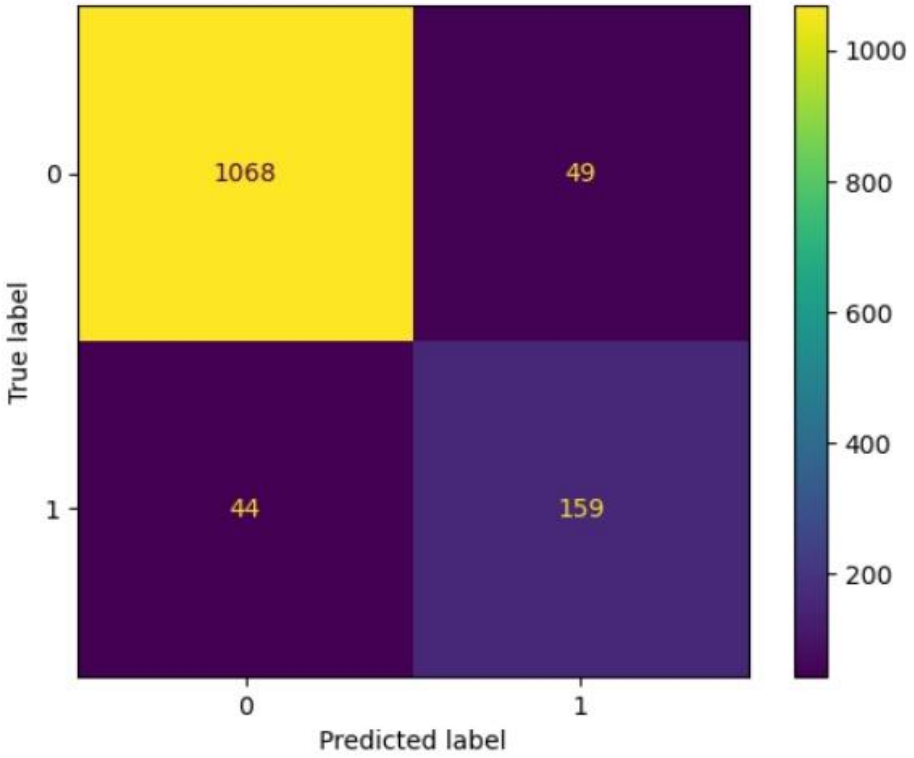

	precision	recall	f1-score	support
0.0	0.96	0.96	0.96	1117
1.0	0.76	0.78	0.77	203
accuracy			0.93	1320
macro avg	0.86	0.87	0.87	1320
weighted avg	0.93	0.93	0.93	1320

Za razliku od Decision Tree modela, **SVM** pokazuje znatno bolje i uravnoteženije performanse. Ukupna tačnost iznosi oko 96%, ali detaljnija analiza po klasama otkriva dodatne važne uvide. Za dominantnu klasu (0.0), model postiže vrlo visoke vrijednosti precision i recall (≈ 0.96 i 0.99), što znači da gotovo sve instance ove klase bivaju ispravno klasifikovane.

Kod manjinske klase (1.0), precision je također visok (≈ 0.94), što ukazuje na to da model rijetko pogrešno označava druge instance kao ovu klasu. Međutim, recall je primjetno niži (≈ 0.77), što znači da model propušta određeni broj stvarnih pozitivnih instanci. Drugim riječima, iako su predikcije za klasu 1.0 uglavnom tačne, model ne uspijeva da prepozna sve njene primjere.

	precision	recall	f1-score	support
0.0	0.96	0.99	0.98	1117
1.0	0.94	0.77	0.85	203
accuracy			0.96	1320
macro avg	0.95	0.88	0.91	1320
weighted avg	0.96	0.96	0.96	1320

F1-score za manjinsku klasu (≈ 0.85) pokazuje bolji balans između precision i recall u odnosu na Decision Tree model, što ukazuje na ukupno kvalitetnije ponašanje. Također, macro prosek (≈ 0.91) i weighted prosek (≈ 0.96) potvrđuju da model postiže stabilne performanse uprkos nebalansiranosti klasa.

Ovi rezultati sugerišu da SVM uspijeva da pronađe kvalitetnu granicu razdvajanja između klasa i generalizuje bolje od jednostavnih modela poput stabla odlučivanja, iako i dalje postoji prostor za poboljšanje u detekciji manjinske klase.

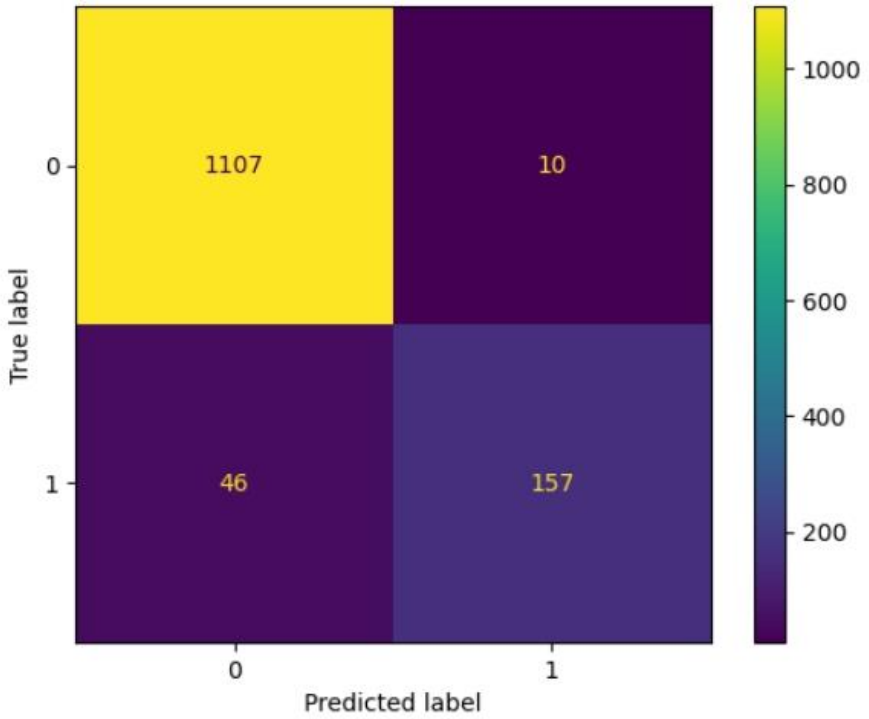

Na osnovu ovih početnih rezultata može se zaključiti da različiti modeli pokazuju različite slabosti i prednosti: linearni modeli imaju stabilnu generalizaciju, stabla su sklona overfitting-u, dok ansambl i kernel metode postižu najbolji balans između tačnosti i generalizacije.

Ovi rezultati predstavljaju osnovu za naredni korak u analizi, koji podrazumijeva detaljnije ispitivanje svakog modela kroz podešavanje hiperparametara i poređenje njihovog uticaja na performanse.

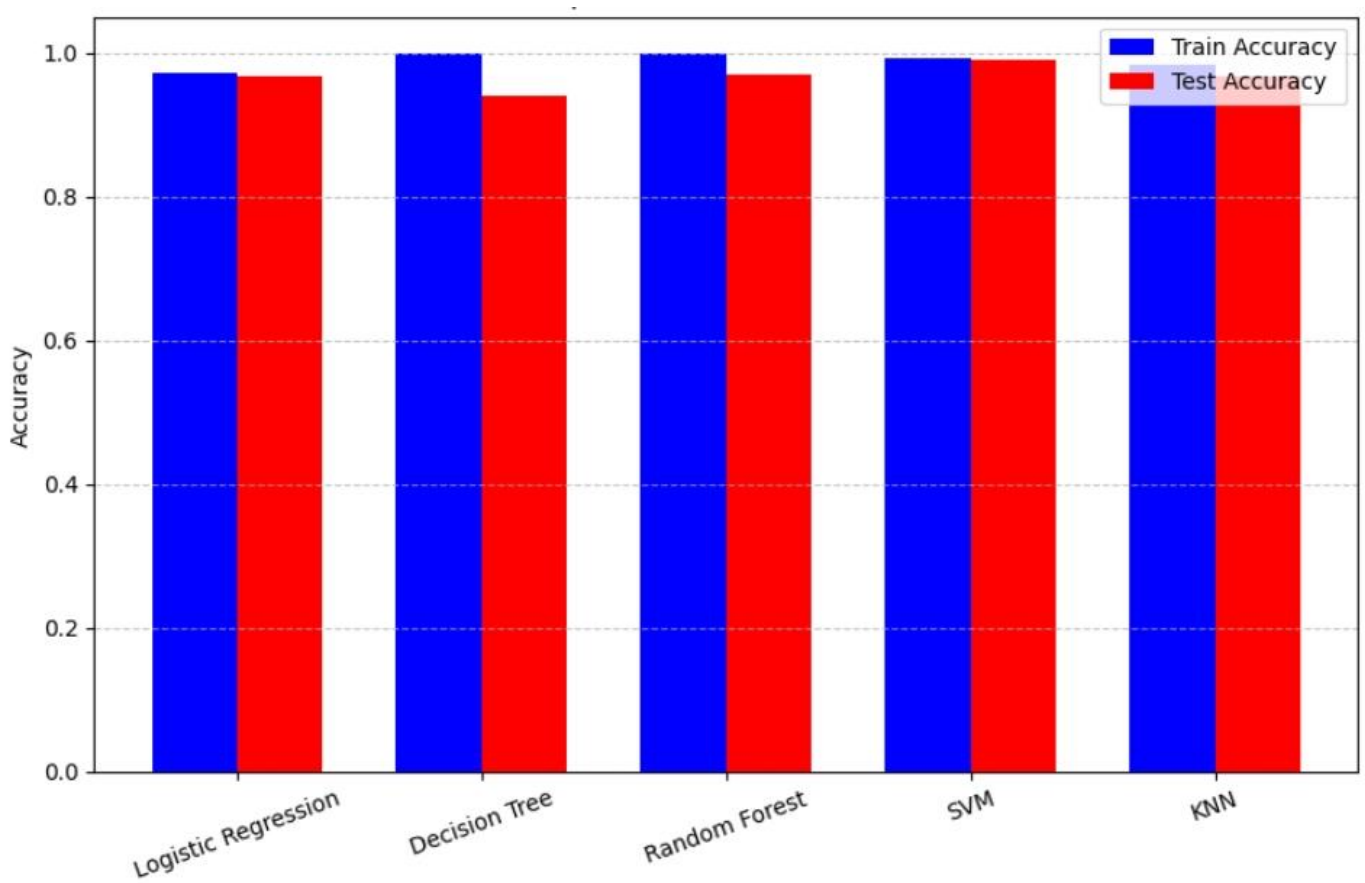

Podešavanje hiperparametara u svrhu poboljšanja modela

Logistic Regression

U cilju ispitivanja uticaja hiperparametara na performanse modela, kod Logistic Regression algoritma analiziran je parametar **C**, koji kontroliše jačinu regularizacije. Ovaj parametar predstavlja inverznu vrijednost regularizacije – manja vrijednost C znači jaču regularizaciju (stroži model), dok veća vrijednost omogućava modelu veću fleksibilnost i potencijalno bolje prilagođavanje podacima.

U eksperimentu su korišćene tri konfiguracije:

- podrazumijevana vrijednost (*C = 1)*
- manja vrijednost (*C = 0.5)*
- veća vrijednost (*C = 2)*

	Model	Train accuracy	Test accuracy
0	LogReg (Default)	0.91152	0.909848
1	LogReg (C=0.5)	0.91152	0.909848
2	LogReg (C=2)	0.91152	0.909848

Rezultati pokazuju da se performanse modela ne mijenjaju drastično promjenom ovog parametra, što ukazuje na relativnu stabilnost Logistic Regression modela u ovom problemu. Razlike između trening i test tačnosti ostaju male u svim slučajevima, što potvrđuje dobru sposobnost generalizacije i odsustvo izraženog overfitting-a.

Blago smanjenje vrijednosti parametra C (jača regularizacija) dovodi do nešto „strožeg" modela koji je manje sklon prilagođavanju šumu u podacima, dok povećanje vrijednosti C omogućava modelu da bolje prati obrasce iz trening skupa. Ipak, u ovom slučaju nijedna od ovih promjena nije dovela do značajnog poboljšanja performansi, što sugeriše da ovom problemu dodatna fleksibilnost ne donosi veliku korist.

```
Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.93      0.97      0.95      1117
         1.0       0.76      0.60      0.67       203

    accuracy                           0.91      1320
   macro avg       0.85      0.78      0.81      1320
weighted avg       0.90      0.91      0.91      1320
```

Analiza klasifikacionog izvještaja za najbolju konfiguraciju pokazuje da model veoma dobro klasifikuje dominantnu klasu (0.0), sa visokim vrijednostima precision i recall (≈ 0.93–0.97). Međutim, performanse na manjinskoj klasi (1.0) su znatno slabije, posebno u pogledu recall vrijednosti (≈ 0.60), što ukazuje na to da model propušta značajan broj instanci ove klase.

F1-score za manjinsku klasu (≈ 0.67) dodatno potvrđuje da Logistic Regression ima ograničenu sposobnost razlikovanja složenijih obrazaca koji karakterišu ovu klasu. Ovo je očekivano, s obzirom na to da je u pitanju linearan model koji ne može u potpunosti da uhvati nelinearne odnose u podacima.

Na osnovu ovih rezultata može se zaključiti da Logistic Regression predstavlja stabilan i robustan model, ali sa ograničenjima u detekciji manjinske klase, što ukazuje na potrebu za složenijim modelima u daljoj analizi.

SVM

Kod SVM modela analiziran je uticaj hiperparametra **C**, koji ima ključnu ulogu u određivanju granice razdvajanja između klasa. Manje vrijednosti C uvode jaču regularizaciju, čime model postaje „stroži" i manje sklon overfitting-u, dok veće vrijednosti omogućavaju modelu veću fleksibilnost i bolje prilagođavanje podacima.

U ovom eksperimentu korišćene su tri konfiguracije:

- podrazumijevana vrijednost (*C = 1*)
- manja vrijednost (*C = 0.8*)
- veća vrijednost (*C = 1.2*)

	Model	Train accuracy	Test accuracy
0	SVM (Default)	0.960970	0.957576
1	SVM (C=0.8)	0.958507	0.954545
2	SVM (C=1.2)	0.965138	0.958333

Rezultati pokazuju da SVM model ostvaruje veoma visoke i stabilne performanse u svim konfiguracijama. Razlika između trening i test tačnosti je mala, što ukazuje na dobru generalizaciju modela. Blago povećanje vrijednosti parametra C (*C = 1.2*) dovodi do najboljih rezultata na test skupu, što sugeriše da model ima koristi od nešto veće fleksibilnosti u ovom slučaju.

Smanjenje vrijednosti C (*C = 0.8*) dovodi do blagog pada performansi, što je očekivano jer jača regularizacija može ograničiti sposobnost modela da uoči složenije obrasce u podacima.

```
Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.96      0.99      0.98      1117
         1.0       0.95      0.77      0.85       203

    accuracy                           0.96      1320
   macro avg       0.95      0.88      0.91      1320
weighted avg       0.96      0.96      0.96      1320
```

Analiza klasifikacionog izvještaja za najbolju konfiguraciju pokazuje vrlo dobre rezultate za dominantnu klasu (0.0), sa gotovo savršenim recall (≈ 0.99) i visokim precision (≈ 0.96). Kod manjinske klase (1.0), precision je takođe visok (≈ 0.95), što znači da model rijetko pravi lažno pozitivne greške. Međutim, recall (≈ 0.77) ukazuje na to da model i dalje propušta određeni broj instanci ove klase.

F1-score za manjinsku klasu (≈ 0.85) pokazuje dobar balans između precision i recall, znatno bolji nego kod jednostavnijih modela poput Logistic Regression. Takođe, visoke vrijednosti macro i weighted prosjeka potvrđuju da model postiže stabilne performanse uprkos nebalansiranosti klasa.

Na osnovu ovih rezultata može se zaključiti da SVM predstavlja jedan od najuspješnijih modela u ovom projektu, sa dobrim balansom između tačnosti i generalizacije, kao i sposobnošću da modeluje složenije odnose u podacima.

Decision tree

Kod Decision Tree modela analiziran je uticaj hiperparametra **max_depth**, koji određuje maksimalnu dubinu stabla i direktno kontroliše njegovu složenost. Podrazumijevana vrijednost (*max_depth=None*) omogućava stablu da raste sve dok potpuno ne razdvoji podatke, što često dovodi do prekomjernog prilagođavanja (overfitting-a).

	Model	Train accuracy	Test accuracy
0	DT (Default)	1.000000	0.930303
1	DT (max_depth=6)	0.938613	0.921212
2	DT (max_depth=8)	0.958507	0.927273

Rezultati za podrazumijevani model jasno pokazuju ovaj problem – model postiže savršenu tačnost na trening skupu (1.00), dok je tačnost na test skupu primjetno niža (≈ 0.93). Ovakvo ponašanje ukazuje na to da model uči specifične obrasce i šum iz trening podataka, ali ne uspijeva da ih generalizuje na neviđene primjere.

Kako bi se smanjio overfitting, uvedena su ograničenja na dubinu stabla, pri čemu su testirane vrijednosti *max_depth = 6* i *max_depth = 8*. Smanjenje dubine dovodi do jednostavnijeg modela koji manje prati šum u podacima. Kod modela sa *max_depth = 6* primjećuje se pad tačnosti na trening skupu (≈ 0.94), ali i blago smanjenje performansi na test skupu (≈ 0.92), što ukazuje na moguće podprilagođavanje (underfitting).

Povećanjem dubine na *max_depth = 8* model postaje fleksibilniji, što dovodi do poboljšanja performansi u odnosu na pliće stablo (test tačnost ≈ 0.93), ali i dalje bez dostizanja savršene tačnosti na trening skupu. Ovaj rezultat pokazuje da postoji kompromis između složenosti modela i njegove sposobnosti generalizacije.

```
Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.96      0.96      0.96      1117
         1.0       0.77      0.78      0.77       203

    accuracy                           0.93      1320
   macro avg       0.87      0.87      0.87      1320
weighted avg       0.93      0.93      0.93      1320
```

Analiza klasifikacionog izvještaja za najbolju konfiguraciju pokazuje da model dobro klasifikuje dominantnu klasu (0.0), sa visokim vrijednostima precision i recall (≈ 0.96). Međutim, kod manjinske klase (1.0) performanse su slabije (precision ≈ 0.77, recall ≈ 0.78), što ukazuje na poteškoće u prepoznavanju ove klase.

F1-score za manjinsku klasu (≈ 0.77) potvrđuje da model postiže umjeren balans između preciznosti i odziva, ali i dalje zaostaje u odnosu na kompleksnije modele. Iako ukupna tačnost djeluje zadovoljavajuće, analiza po klasama pokazuje da Decision Tree nije optimalan izbor za ovaj problem bez dodatnog podešavanja.

Na osnovu ovih rezultata može se zaključiti da je Decision Tree model vrlo osjetljiv na izbor hiperparametara, posebno dubine stabla, te da zahtijeva pažljivo podešavanje kako bi se postigao balans između overfitting-a i underfitting-a.

KNN

Kod KNN modela analiziran je uticaj dva ključna hiperparametra: **broj susjeda (n_neighbors)** i način ponderisanja susjeda (**weights**). Ovi parametri direktno utiču na način donošenja odluke i osjetljivost modela na lokalnu strukturu podataka.

U eksperimentu su korišćene tri konfiguracije:

- podrazumijevana vrijednost (*n_neighbors = 5*, uniformno ponderisanje)
- manji broj susjeda (*n_neighbors = 4*)
- *n_neighbors = 4* uz ponderisanje po udaljenosti (*weights = 'distance'*)

Smanjenje broja susjeda dovodi do toga da model više pažnje posvećuje najbližim instancama, čime postaje osjetljiviji na lokalne obrasce u podacima. Rezultati pokazuju da ova promjena donosi blago poboljšanje performansi na test skupu, što ukazuje na to da su bliži susjedi informativniji za ovaj problem.

	Model	Train accuracy	Test accuracy
0	KNN (Default)	0.975748	0.956061
1	KNN (n_neighbors=4)	0.974801	0.960606
2	KNN (n_neighbors=4+distance)	1.000000	0.967424

Dodatno poboljšanje postiže se uvođenjem ponderisanja po udaljenosti, gdje bliži susjedi imaju veći uticaj na odluku modela. Ova konfiguracija dovodi do najboljih rezultata, pri čemu model postiže savršenu tačnost na trening skupu (1.00) i najvišu tačnost na test skupu (≈ 0.97). Iako savršena tačnost na trening podacima može ukazivati na overfitting, visoka test tačnost sugeriše da model i dalje dobro generalizuje.

Analiza klasifikacionog izvještaja za najbolju konfiguraciju pokazuje vrlo dobre performanse za obje klase. Za dominantnu klasu (0.0), precision i recall su gotovo idealni (≈ 0.98–0.99). Za manjinsku klasu (1.0), model postiže značajno bolje rezultate u odnosu na prethodne modele (precision ≈ 0.92, recall ≈ 0.86), što ukazuje na poboljšanu sposobnost prepoznavanja ove klase.

```
Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.98      0.99      0.98      1117
         1.0       0.92      0.86      0.89       203

    accuracy                           0.97      1320
   macro avg       0.95      0.92      0.94      1320
weighted avg       0.97      0.97      0.97      1320
```

F1-score za manjinsku klasu (≈ 0.89) potvrđuje dobar balans između preciznosti i odziva, dok visoke vrijednosti macro i weighted prosjeka ukazuju na stabilne performanse modela uprkos nebalansiranosti podataka.

Na osnovu ovih rezultata može se zaključiti da KNN model, uz adekvatno podešavanje hiperparametara, može postići vrlo visoke performanse i efikasno iskoristiti lokalnu strukturu podataka, posebno kada se primijeni ponderisanje po udaljenosti.

Random Forest

Kod Random Forest modela analiziran je uticaj hiperparametra **max_depth**, koji kontroliše maksimalnu dubinu pojedinačnih stabala unutar ansambla. Iako Random Forest koristi više stabala i na taj način smanjuje varijansu u odnosu na pojedinačno stablo, prevelika dubina i dalje može dovesti do prekomjerne složenosti modela.

U eksperimentu su korišćene tri konfiguracije:

- podrazumijevana vrijednost (*n_estimators = 100*, bez ograničenja dubine)
- ograničena dubina (*max_depth = 6*)
- umjereno ograničena dubina (*max_depth = 8*)

	Model	Train accuracy	Test accuracy
0	Radom Forest (Default)	1.000000	0.953030
1	Radom Forest (max_depth=6)	0.931413	0.920455
2	Radom Forest (max_depth=8)	0.961160	0.937879

Podrazumijevani model postiže savršenu tačnost na trening skupu (1.00), što ukazuje na visoku fleksibilnost modela, dok na test skupu ostvaruje vrlo dobre performanse (≈ 0.95). Za razliku od Decision Tree modela, ovdje visoka trening tačnost ne dovodi do značajnog pada performansi na test skupu, što potvrđuje robusnost ansambl pristupa.

Smanjenjem dubine na *max_depth = 6* dolazi do značajnog pada tačnosti i na trening i na test skupu (≈ 0.93 i ≈ 0.92), što ukazuje na to da model postaje previše ograničen i gubi sposobnost da adekvatno modeluje složenost podataka. Povećanjem dubine na *max_depth = 8* postiže se bolji balans (test tačnost ≈ 0.94), ali i dalje nešto slabiji u odnosu na podrazumijevani model.

```
Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.95      1.00      0.97      1117
         1.0       0.97      0.71      0.82       203

    accuracy                           0.95      1320
   macro avg       0.96      0.86      0.90      1320
weighted avg       0.95      0.95      0.95      1320
```

Analiza klasifikacionog izvještaja za najbolju konfiguraciju (default) pokazuje vrlo dobre performanse za dominantnu klasu (0.0), sa gotovo savršenim recall (≈ 1.00) i visokim precision (≈ 0.95). Kod manjinske klase (1.0), model postiže vrlo visok precision (≈ 0.97), što znači da rijetko pravi greške u pozitivnim predikcijama, ali recall (≈ 0.71) ukazuje na to da propušta određeni broj stvarnih instanci ove klase.

F1-score za manjinsku klasu (≈ 0.82) pokazuje solidan balans između preciznosti i odziva, ali i dalje zaostaje u odnosu na najbolje modele poput KNN ili SVM. Macro prosjek (≈ 0.90) i weighted prosjek (≈ 0.95) potvrđuju da model ostvaruje stabilne performanse uprkos nebalansiranosti podataka.

Na osnovu ovih rezultata može se zaključiti da Random Forest predstavlja vrlo snažan i robustan model, koji uspješno prevazilazi probleme pojedinačnih stabala, ali i dalje može imati poteškoće u detekciji manjinske klase. Uprkos tome, pokazuje visok nivo tačnosti i stabilnosti, što ga čini jednim od najboljih modela u ovom projektu.

Komparativna analiza modela na PCA-redukovanim podacima

Na osnovu sprovedenih eksperimenata nad dimenziono redukovanim podacima, može se uočiti da različiti modeli pokazuju značajne razlike u performansama, ali i u načinu na koji reaguju na promjene hiperparametara.

Linearni model, **Logistic Regression**, pokazao je stabilno ponašanje i dobru generalizaciju, ali ograničene mogućnosti u prepoznavanju složenijih obrazaca, posebno kod manjinske klase.

Decision Tree model se pokazao osjetljivim na izbor hiperparametara, sa izraženim problemom overfitting-a kod podrazumijevane konfiguracije, dok je kontrola dubine omogućila bolji balans između složenosti i generalizacije.

Sa druge strane, **Random Forest** je demonstrirao znatno veću robusnost u odnosu na pojedinačno stablo, postižući visoku tačnost i stabilne rezultate, iako i dalje sa određenim ograničenjima u detekciji manjinske klase.

SVM model se istakao kao jedan od najuspješnijih, sa dobrim balansom između tačnosti i generalizacije, kao i sposobnošću da modeluje složenije odnose u podacima.

Najbolje ukupne performanse ostvario je **KNN** model uz odgovarajuće podešavanje hiperparametara, posebno uz ponderisanje po udaljenosti, čime je postignut vrlo dobar balans između preciznosti i odziva za obje klase.

Na osnovu ovih rezultata može se zaključiti da izbor modela i hiperparametara ima značajan uticaj na performanse, te da složeniji modeli i oni koji uzimaju u obzir lokalnu strukturu podataka daju bolje rezultate na ovom skupu. U nastavku rada, dodatna analiza biće sprovedena nad originalnim (raw) podacima, kako bi se ispitao uticaj redukcije dimenzionalnosti na performanse modela.

Evaluacija na originalnim (raw) podacima

Nakon analize performansi modela nad dimenziono redukovanim podacima, u nastavku rada izvršena je evaluacija istih modela nad originalnim (raw) skupom podataka. Cilj ovog koraka je ispitivanje uticaja redukcije dimenzionalnosti na performanse modela, odnosno poređenje rezultata dobijenih nad transformisanim i netransformisanim podacima.

Proces pripreme podataka u ovom slučaju uključivao je učitavanje originalnog skupa podataka, definisanje atributa, kao i izdvajanje ulaznih i ciljnih promjenljivih. Kao i u prethodnim eksperimentima, iz skupa su uklonjeni identifikacioni atributi (**ID** i **attr_1**), dok je atribut **attr_168** korišćen kao ciljna promjenljiva.

Iako nije primijenjena redukcija dimenzionalnosti, zadržano je skaliranje podataka korišćenjem *StandardScaler* metode. Skaliranje je i dalje neophodno zbog različitih opsega numeričkih atributa, kao i zbog modela koji su osjetljivi na skalu podataka, poput SVM i KNN. Kao i ranije, skaliranje je izvršeno isključivo na trening skupu, a zatim primijenjeno na test skup.

Za potrebe poređenja, korišćeni su isti modeli i iste konfiguracije hiperparametara koje su se pokazale kao najbolje u eksperimentima sa PCA-redukovanim podacima. Na ovaj način omogućena je direktna i fer usporedba performansi.

Ovakav pristup omogućava jasnije sagledavanje uloge redukcije dimenzionalnosti: da li PCA doprinosi poboljšanju performansi modela ili, u određenim slučajevima, dolazi do gubitka korisnih informacija koji može negativno uticati na rezultate.

U nastavku poglavlja biće prikazani rezultati za svaki model pojedinačno, uz analizu njihovog ponašanja i poređenje sa prethodno dobijenim rezultatima nad redukovanim podacima.

Logistic Regression

Na originalnim (raw) podacima Logistic Regression model je treniran bez primjene PCA redukcije, uz zadržano standardno skaliranje ulaznih atributa. Rezultati pokazuju da model ostvaruje stabilne performanse, sa tačnošću od približno 0.96 na trening skupu i 0.95 na test skupu, što ukazuje na dobru sposobnost generalizacije i odsustvo značajnog overfitting-a.

```
Logistic Regression - Train Accuracy: 0.9573702159909057
Logistic Regression - Test Accuracy:  0.953030303030303

Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.96      0.98      0.97      1117
         1.0       0.88      0.80      0.84       203

    accuracy                           0.95      1320
   macro avg       0.92      0.89      0.91      1320
weighted avg       0.95      0.95      0.95      1320
```

Analiza klasifikacionog izvještaja pokazuje da model vrlo dobro prepoznaje dominantnu klasu (0.0), sa visokim vrijednostima precision i recall (≈ 0.96–0.98). U poređenju sa PCA varijantom, primjećuje se poboljšanje u prepoznavanju manjinske klase (1.0), gdje su precision i recall značajno viši (≈ 0.88 i 0.80), što rezultira boljim F1-score-om (≈ 0.84).

Ovi rezultati sugerišu da Logistic Regression model bolje iskorištava informacije kada se koristi kompletan skup originalnih atributa, jer redukcija dimenzionalnosti može dovesti do gubitka dijela diskriminativnih informacija važnih za separaciju klasa. Ukupno posmatrano, model pokazuje vrlo dobre i stabilne performanse na raw podacima.

SVM

Na originalnim (raw) podacima SVM model je treniran uz prethodno određeni optimalni parametar **C = 1.2**, koji je pokazao najbolje performanse u eksperimentima na PCA-redukovanim podacima. Kao i u prethodnim slučajevima, podaci su standardizovani kako bi se obezbijedila konzistentnost i pravilno funkcionisanje modela koji je osjetljiv na skalu atributa.

Dobijeni rezultati pokazuju veoma visoke performanse modela, sa tačnošću od približno 0.98 na trening skupu i 0.97 na test skupu. Mala razlika između trening i test tačnosti ukazuje na stabilnu generalizaciju i odsustvo značajnog overfitting-a.

```
SVM - Train Accuracy: 0.9784009094353922
SVM - Test Accuracy:  0.9727272727272728

Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.98      0.99      0.98      1117
         1.0       0.95      0.87      0.91       203

    accuracy                           0.97      1320
   macro avg       0.96      0.93      0.95      1320
weighted avg       0.97      0.97      0.97      1320
```

Analiza klasifikacionog izvještaja pokazuje da model gotovo savršeno prepoznaje dominantnu klasu (0.0), sa vrijednostima precision i recall od oko 0.98–0.99. Za manjinsku klasu (1.0), performanse su takođe veoma visoke, sa precision od oko 0.95 i recall od oko 0.87, što predstavlja poboljšanje u odnosu na PCA varijantu modela.

F1-score za manjinsku klasu (≈ 0.91) dodatno potvrđuje da SVM na raw podacima postiže vrlo dobar balans između preciznosti i odziva, te bolje identifikuje složenije obrasce u podacima kada su sve originalne karakteristike uključene.

Ovi rezultati ukazuju da SVM model efikasno koristi visokodimenzionalni prostor originalnih podataka. Ukupno posmatrano, SVM se potvrđuje kao jedan od najjačih modela u oba pristupa.

KNN

Na originalnim (raw) podacima KNN model je treniran sa prethodno odabranim hiperparametrima (*n_neighbors = 4* i *weights = 'distance'*), koji su se u ranijim eksperimentima pokazali kao optimalna konfiguracija. Kao i kod ostalih modela, primijenjeno je standardno skaliranje podataka kako bi se obezbijedilo ispravno računanje udaljenosti između instanci.

Dobijeni rezultati pokazuju veoma visoke performanse modela, sa savršenom tačnošću na trening skupu (1.00) i visokom tačnošću na test skupu (≈ 0.97). Iako savršena tačnost na trening podacima može ukazivati na određeni stepen preprilagođavanja, visoka test tačnost potvrđuje da model i dalje dobro generalizuje.

```
KNN - Train Accuracy: 1.0
KNN - Test Accuracy:  0.9674242424242424

Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.97      0.99      0.98      1117
         1.0       0.93      0.86      0.89       203

    accuracy                           0.97      1320
   macro avg       0.95      0.92      0.94      1320
weighted avg       0.97      0.97      0.97      1320
```

Analiza klasifikacionog izvještaja pokazuje da KNN vrlo dobro prepoznaje dominantnu klasu (0.0), sa vrijednostima precision i recall od oko 0.97–0.99. Za manjinsku klasu (1.0), model postiže visoke vrijednosti precision (≈ 0.93) i recall (≈ 0.86), što ukazuje na dobru sposobnost detekcije pozitivne klase.

F1-score za manjinsku klasu (≈ 0.89) potvrđuje da model ostvaruje dobar balans između preciznosti i odziva, uz nešto slabije performanse u odnosu na SVM, ali bolje u odnosu na jednostavnije modele poput Logistic Regression.

Ovi rezultati pokazuju da KNN model efikasno koristi lokalnu strukturu podataka i da, uz pravilno podešavanje hiperparametara i skaliranje, može postići vrlo konkurentne rezultate na originalnom skupu podataka.

Decision Tree

Na originalnim (raw) podacima Decision Tree model je treniran sa podrazumijevanim hiperparametrima, bez dodatnog ograničavanja složenosti stabla. Kao i u prethodnim eksperimentima, ulazni podaci su prethodno standardizovani kako bi se obezbijedila konzistentnost u obradi, iako Decision Tree u osnovi nije osjetljiv na skaliranje.

Dobijeni rezultati pokazuju da model postiže savršenu tačnost na trening skupu (1.00), što ukazuje da je stablo u potpunosti naučilo obrasce iz trening podataka. Međutim, za razliku od prethodnih slučajeva, ovdje se ne primjećuje značajan pad performansi na test skupu, gdje model ostvaruje visoku tačnost od približno 0.97.

```
Decision Tree - Train Accuracy: 1.0
Decision Tree - Test Accuracy:  0.968939393939394

Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.98      0.98      0.98      1117
         1.0       0.90      0.90      0.90       203

    accuracy                           0.97      1320
   macro avg       0.94      0.94      0.94      1320
weighted avg       0.97      0.97      0.97      1320
```

Analiza klasifikacionog izvještaja pokazuje vrlo dobre i uravnotežene performanse za obje klase. Za dominantnu klasu (0.0), precision i recall su oko 0.98, dok za manjinsku klasu (1.0) model postiže visoke vrijednosti (≈ 0.90 za oba pokazatelja), što ukazuje na bolju sposobnost prepoznavanja pozitivne klase u odnosu na prethodne varijante modela na PCA podacima.

F1-score za obje klase je visok i iznosi oko 0.98 za dominantnu i 0.90 za manjinsku klasu, što pokazuje da model postiže dobar balans između preciznosti i odziva. Ovakvi rezultati sugerišu da Decision Tree, iako jednostavan model, na raw podacima uspijeva da zadrži visok nivo performansi bez izraženog pogoršanja generalizacije.

U poređenju sa PCA varijantom, može se primijetiti da korišćenje originalnih podataka omogućava bolju detekciju manjinske klase i stabilnije ukupne rezultate, iako model i dalje ostaje sklon potpunom prilagođavanju trening skupu.

Random Forest

Na originalnim (raw) podacima Random Forest model je treniran sa podrazumijevanim hiperparametrima i uz fiksiran **random_state** radi reproduktivnosti rezultata. Kao i u prethodnim slučajevima, podaci su prethodno standardizovani, iako ovaj model u osnovi nije osjetljiv na skalu atributa, već na strukturu i informativnost samih varijabli.

Dobijeni rezultati pokazuju da model postiže savršenu tačnost na trening skupu (1.00), što je očekivano s obzirom na njegovu fleksibilnost i sposobnost kombinovanja velikog broja odluka iz pojedinačnih stabala. Na test skupu model ostvaruje vrlo visoku tačnost od približno 0.97, što ukazuje na dobru generalizaciju i stabilne performanse.

```
Random Forest - Train Accuracy: 1.0
Random Forest - Test Accuracy:  0.9712121212121212

Classification Report (Test set):
              precision    recall  f1-score   support

         0.0       0.97      1.00      0.98      1117
         1.0       0.97      0.84      0.90       203

    accuracy                           0.97      1320
   macro avg       0.97      0.92      0.94      1320
weighted avg       0.97      0.97      0.97      1320
```

Analiza klasifikacionog izvještaja pokazuje da Random Forest veoma dobro prepoznaje dominantnu klasu (0.0), sa gotovo savršenim recall (≈ 1.00) i visokim precision (≈ 0.97). Za manjinsku klasu (1.0), model takođe postiže vrlo dobre rezultate, sa precision oko 0.97 i recall oko 0.84, što predstavlja značajno poboljšanje u odnosu na jednostavno Decision Tree stablo.

F1-score za manjinsku klasu (≈ 0.90) potvrđuje da model uspješno balansira preciznost i odziv, i da relativno dobro identifikuje i rjeđe pojave u podacima. Macro i weighted prosjeci dodatno potvrđuju stabilnost modela i njegovu otpornost na nebalansiranost klasa.

U poređenju sa PCA varijantom, Random Forest na raw podacima pokazuje blago bolje performanse, posebno u pogledu prepoznavanja manjinske klase, što sugeriše da dodatne originalne karakteristike doprinose boljoj diskriminaciji između klasa. Ukupno posmatrano, ovaj model ostaje jedan od najstabilnijih i najpouzdanijih u okviru sprovedene analize.

Poređenje performansi modela na raw i PCA-redukovanim podacima

Uporedna analiza rezultata pokazuje da su svi modeli ostvarili vrlo dobre performanse i na originalnim (raw) i na dimenziono redukovanim (PCA) podacima, ali uz određene razlike u kvalitetu klasifikacije. U većini slučajeva PCA redukcija nije značajno narušila ukupnu tačnost modela, što ukazuje da prvih 20 glavnih komponenti uspješno zadržava većinu relevantnih informacija iz originalnog skupa podataka.

Ipak, modeli trenirani na raw podacima u pojedinim slučajevima pokazuju blago bolje performanse, posebno u detekciji manjinske klase, što sugeriše da dio diskriminativnih informacija može biti izgubljen tokom PCA transformacije. S druge strane, PCA pristup doprinosi smanjenju dimenzionalnosti i kompleksnosti modela, što može poboljšati efikasnost i stabilnost u treniranju.

Generalno posmatrano, razlike između ova dva pristupa su male, a izbor optimalnog pristupa zavisi od balansa između interpretabilnosti, brzine treniranja i minimalnog gubitka informacija.

Zaključak i osvrt na projekat

U okviru ovog projekta obrađen je problem binarne klasifikacije molekula na **MUSK** i **NON-MUSK** klase korišćenjem različitih metoda mašinskog učenja. Osnovni cilj bio je izgradnja i poređenje više klasifikacionih modela, kao i analiza uticaja pretprocesiranja podataka, posebno skaliranja i redukcije dimenzionalnosti, na krajnje performanse.

Tokom rada je izvršena detaljna analiza početnog skupa podataka, koji se odlikuje velikim brojem numeričkih atributa i visokom dimenzionalnošću. S obzirom na to, značajan fokus je bio na pripremi podataka, uključujući standardizaciju i primjenu PCA metode.

Implementirani su različiti modeli mašinskog učenja: Logistic Regression, Decision Tree, Random Forest, Support Vector Machine i K-Nearest Neighbors. Svaki od modela ima različit pristup učenju, od linearnih granica, preko ansambl metoda, do lokalnih i margin-based algoritama.

Eksperimenti su sprovedeni u dvije varijante — na PCA-redukovanim i na originalnim (raw) podacima. Rezultati su pokazali da svi modeli postižu visoke performanse, ali da određene razlike postoje u zavisnosti od reprezentacije podataka i izbora hiperparametara. Ansambl i kernel metode (Random Forest, SVM i KNN) pokazale su se kao najstabilnije i najpreciznije, dok je Logistic Regression dao solidne, ali nešto slabije rezultate u pogledu detekcije kompleksnijih obrazaca. Decision Tree model je bio najosjetljiviji na overfitting, ali je kroz ograničavanje dubine postignut bolji balans između trening i test performansi.

Poređenjem PCA i raw pristupa može se zaključiti da redukcija dimenzionalnosti nije značajno narušila kvalitet klasifikacije, ali je u određenim slučajevima dovela do blagog gubitka informacija važnih za prepoznavanje manjinske klase.

Ipak, PCA je doprinio smanjenju kompleksnosti i poboljšanju efikasnosti treniranja modela.

U cjelini, ovaj projekat predstavlja zanimljiv i izazovan zadatak koji kombinuje više aspekata mašinskog učenja — od pripreme podataka, preko redukcije dimenzionalnosti, do optimizacije i evaluacije različitih modela.

Rad na ovom projektu omogućio mi je bolje razumijevanje ponašanja različitih algoritama, njihovih prednosti i ograničenja, kao i značaja pravilnog pretprocesiranja podataka u procesu izgradnje modela.

Na ličnom nivou, projekat je bio izuzetno koristan i zanimljiv, kombinovao je strogi i planirani pristup protkan kreativnošću. Kroz podešavanje hiperparametara osjećala sam određenu slobodu da sopstvenim nahođenjem upravljam projektom i kontrolišem njegov tok ali ne gubeći iz vida svoj cilj - unapređivanje algoritama klasifikacije i njihove tačnosti.